

PIPELINE DE QUALITÉ DE DONNÉES

Un chiffre faux se voit après coup.

Anatomie d'un pipeline conçu pour le détecter avant qu'il n'arrive en reporting.

LE PROBLÈME

**Les données arrivent brutes,
hétérogènes, jamais
conformes au RGPD par
défaut.**

Sans contrôle explicite à l'entrée, une anomalie de qualité se propage silencieusement jusqu'au reporting.



L'ARCHITECTURE EN 4 ÉTAPES

1

Ingestion

Les données brutes entrent dans le pipeline, telles quelles.

2

Règles de qualité (YAML)

Chaque contrôle est déclaré dans un fichier, pas codé en dur.

3

Anonymisation RGPD

Les champs sensibles sont pseudonymisés par hachage.

4

Entrepôt en étoile (DuckDB)

Les données propres atterrissent, prêtes pour l'analyse.

ÉTAPE 1 • RÈGLES DÉCLARATIVES

Les règles de qualité sont écrites en YAML, pas codées en dur.

Une nouvelle règle métier s'ajoute au fichier de configuration, sans redéploiement du pipeline.

```
REGLES_QUALITE.YAML
```

```
regle: format_email  
colonne: email  
controle: regex_valide  
seuil: 0.98
```

ÉTAPE 2 • ANONYMISATION RGPD

Les identifiants sensibles sont pseudonymisés par hachage avant tout reporting.

La donnée en clair reste dans la zone protégée ; le reporting ne manipule jamais l'identité brute.

`marie.dupont@mutuelle.fr`




`a13f9c2d7e4b...`

🔒 Zone protégée, jamais exposée telle quelle en aval.

ÉTAPE 3 • SCORECARD QUALITÉ

La qualité est visible en continu, pas vérifiée une fois par audit.

Chaque exécution du pipeline met à jour un score par dimension de qualité.



Aperçu illustratif du scorecard généré par le pipeline.

LA PREUVE

17 tests automatisés valident le pipeline à chaque exécution.

Avant d'être montré, le pipeline est testé. Pas une promesse, une vérification répétable.

- ✓ Complétude et formats des champs
- ✓ Unicité des identifiants
- ✓ Cohérence de l'anonymisation
- ✓ Intégrité de l'entrepôt en étoile

ALLER PLUS LOIN

La démo est en ligne.

```
data-quality-pipeline.streamlit.app >
```

Un commentaire suffit si vous voulez qu'on regarde votre cas ensemble.