

EXTRACTION DE DOCUMENTS

Avant d'écrire la première ligne d'extraction, j'ai trouvé un bug qui n'existait pas encore

Une bonne partie du travail d'automatisation se joue avant la première extraction.

LE CONTEXTE

Comment vérifier la cohérence d'une facture, automatiquement

Je voulais comprendre comment un outil peut lire une facture PDF et vérifier HT, TVA et TTC, alors j'ai construit un moteur d'extraction déclarative, sur 40 factures simulées avec de vraies entreprises Sirene comme fournisseurs.

LE BUG TROUVÉ AVANT DE CODER

Vérifier avant, pas découvrir en pleine extraction

- 01 La dernière version d'une librairie de lecture PDF s'est révélée incompatible avec Python installé sur mon poste.
- 02 Figée à une version antérieure vérifiée, avant d'écrire la moindre ligne de code.
- 03 Le moteur compare 3 montants avec une marge de tolérance, ignore une ligne incomplète plutôt que de la traiter comme fausse.

VÉRIFIÉ, PAS SUPPOSÉ

Testé avant d'être considéré prêt

18

tests automatisés

4

écrans vérifiés un par un dans le navigateur

CE QUE JE RETIENS

Une bonne partie du travail d'automatisation se joue avant la première extraction, dans ce qu'on prend le temps de vérifier.

LE CODE EST SUR GITHUB

Un message suffit si vous voulez qu'on regarde comment l'adapter à vos propres factures.

`github.com/Kingdmfncr/extraction-documents-poc`